

Détection, diagnostic et prévision sur jumeau numérique réseau

Rapport d'étape sur l'implémentation des deux voies et l'évaluation de la voie de prévision

Lizhan Hong · École Polytechnique · Orange Wholesale (OW / OINIS)

Juillet 2026

Table des matières

Résumé	2
1 Introduction et objectif	2
2 Vue d'ensemble du système	3
3 La voie quantitative : implémentation	3
3.1 Principe	3
3.2 Données et modèle de trafic	5
3.3 Variables exogènes et absence de fuite	5
3.4 Modèles comparés	5
3.5 Architecture en deux étapes	6
3.6 Probabilité de dépassement et incident préventif	6
4 Protocole d'évaluation	6
4.1 Rejeu à origine glissante	6
4.2 Mesures d'erreur	6
4.3 Test de significativité	7
4.4 Calibration et dépassement	8
5 Résultats	8
5.1 Résultat principal	8
5.2 Prévision de dépassement	10
5.3 Calibration	10
6 La voie agent : diagnostic agentique	13
6.1 État actuel	13
6.2 Pourquoi la chaîne reste agentique	13
6.3 Déroulé du diagnostic	14
6.4 Outils de diagnostic	14
6.5 Relation au futur raisonneur fondé sur un modèle de langage	14

7 Validité des résultats	15
8 Conclusion et prochaines étapes	15
Références	15

Résumé

Le projet construit, au-dessus d'un jumeau numérique du réseau, un système qui détecte les incidents, en cherche la cause, et prévoit les dépassements de charge avant qu'ils ne surviennent. Le système suit deux voies complémentaires : une voie quantitative qui prévoit la charge et en déduit une probabilité de dépassement, et une voie agent où un raisonneur cherche la cause d'un incident et la vérifie en la rejouant dans le jumeau. Ce rapport décrit l'implémentation des deux voies et présente l'évaluation de la voie de prévision. Sur deux modèles de référence, un modèle naïf saisonnier et le même enrichi de variables connues d'avance, l'ajout de ces variables réduit l'erreur à tous les horizons, avec un gain de 0,71 à l'horizon de travail, statistiquement significatif au test de Diebold-Mariano ($p = 0,002$). Ce résultat repose sur 1728 points de prévision par horizon et est jugé solide. La voie agent est fonctionnelle et repose aujourd'hui sur un raisonneur déterministe à base de règles, qui sert de point de référence reproductible et de témoin expérimental pour un futur raisonneur fondé sur un modèle de langage. La contribution de ce cycle est un protocole d'évaluation rigoureux et sans fuite d'information, et la démonstration que les variables opérationnelles apportent un signal mesurable à la prévision.

1 Introduction et objectif

Le coût d'un incident réseau ne vient pas seulement de la panne, mais du temps nécessaire pour la voir, la comprendre et décider quoi faire. Trois constats motivent ce projet.

D'abord, les erreurs et changements de configuration sont une cause majeure de panne. Une étude classique de la fiabilité des services en ligne montre que l'erreur d'exploitation est la première source de panne de plusieurs services, et que la configuration en est la première catégorie [1]. Une enquête sectorielle récente indique qu'une part importante des pannes majeures reste attribuée à l'erreur humaine et à des procédures de changement défaillantes [2]. Le système doit donc traiter l'audit de configuration et le moment du changement comme des preuves de premier rang.

Ensuite, dans le temps de rétablissement, les phases les plus longues sont la détection et le diagnostic. Les briques de détection et d'analyse de cause visent directement ces deux étapes.

Enfin, poser un diagnostic demande de rapprocher des preuves de natures différentes, la configuration, la télémétrie, la topologie et l'état des protocoles de routage. Les travaux sur l'analyse de cause en réseau confirment qu'une source unique ne suffit pas et qu'il

faut combiner protocoles, topologie et journaux [3]. Le rôle du raisonneur n'est pas de remplacer les outils existants, mais de les orchestrer et de tenir une chaîne de preuves cohérente.

La particularité du système est de disposer d'un jumeau numérique. Un modèle de langage peut produire une cause plausible, mais plausible ne veut pas dire correcte. Ici, une hypothèse de cause doit pouvoir être rejouée dans une copie du jumeau : si le rejeu reproduit les symptômes, l'hypothèse gagne en crédibilité, sinon elle est écartée. Le jumeau n'est donc pas seulement une représentation du réseau, il sert de mécanisme de vérification. Cette notion de jumeau réseau au service de la planification, de l'analyse d'impact et de la gestion du changement rejoint les cadres de référence en cours de normalisation [4], [5].

Ce rapport décrit l'implémentation des deux voies, puis se concentre sur la mise en place et les résultats du protocole d'évaluation de la voie de prévision. Les modèles évalués ici sont volontairement simples : l'objectif de ce cycle est d'établir la méthode de mesure et une base de comparaison, pas de proposer le modèle final.

2 Vue d'ensemble du système

Le système suit deux voies qui ne fonctionnent pas de la même façon.

La voie quantitative calcule des chiffres. À partir de l'historique de charge et de variables connues d'avance, à savoir les changements de configuration, les événements et le calendrier, elle prévoit la charge future avec un intervalle, puis en déduit une probabilité de dépassement. Quand cette probabilité franchit un seuil, elle produit une intention : un dépassement est prévu dans un certain nombre de pas.

La voie agent raisonne sur un incident. La détection repère une anomalie ou une dérive et ouvre un incident ; un raisonneur le reprend, appelle des outils pour rassembler des preuves, propose une cause, la vérifie dans le jumeau, puis conclut.

Les deux voies se rejoignent : un dépassement prévu est traité comme un incident préventif par le même raisonneur, avant la panne. C'est le même objet et le même raisonneur des deux côtés, seule l'origine change, un fait constaté ou un fait prévu (figure 1). Le raisonneur ne détermine pas la cause en une fois ; il procède par étapes et se sert du jumeau pour valider chaque hypothèse (figure 2).

3 La voie quantitative : implémentation

3.1 Principe

L'objectif de cette voie n'est pas de prédire directement une panne, mais d'estimer l'évolution future de la charge, puis d'en déduire une probabilité de dépassement d'un seuil opérationnel. La sortie est donc probabiliste : le modèle produit des quantiles, par exemple p_{50} , p_{90} , p_{95} et p_{99} , afin de représenter l'incertitude utile à la décision. On ne

Figure 1 — Les deux voies et leur point de rencontre




Figure 1: Les deux voies et leur point de rencontre.




Figure 2: La boucle de diagnostic.

se contente pas de la valeur médiane, car un dépassement de capacité est une question de queue de distribution, pas de tendance centrale.

3.2 Données et modèle de trafic

Les données proviennent aujourd'hui du jumeau simulé, qui produit pour chaque interface une série temporelle de télémétrie : taux d'utilisation, erreurs et latence. En mode prévision, le jumeau fonctionne avec des pas de cinq minutes. La tâche utilise l'historique d'utilisation ou de demande par lien.

Dans les scénarios de diagnostic, le trafic est statique. En mode prévision, le jumeau active un modèle de trafic qui donne aux séries une structure apprenable. La demande à l'instant t s'écrit comme le produit d'une charge de base, d'un niveau global, d'une saisonnalité journalière, d'une saisonnalité hebdomadaire, d'une tendance lente, de rampes liées à des événements, et d'un bruit pseudo-aléatoire déterministe. La saisonnalité journalière représente les heures de pointe, la saisonnalité hebdomadaire la différence entre jours ouvrés et week-end, la tendance une croissance lente, et les rampes des événements ou une hausse de la demande client. Le bruit est déterministe, ce qui garde les expériences reproductibles sans dépendre de l'ordre des appels.

3.3 Variables exogènes et absence de fuite

Le modèle enrichi utilise trois familles de variables exogènes : les changements de configuration, les événements réseau et les variables de calendrier. Ce point demande une précaution méthodologique, car il conditionne la validité de toute la comparaison.

Ces variables ne constituent pas une fuite d'information. À chaque origine de prévision, le modèle n'accède qu'à ce qui était connu à cet instant. Les changements de configuration et les événements sont tronqués à l'origine de prévision. Les variables de calendrier, elles, sont admises pour les horizons futurs, parce que la date et l'heure sont connues d'avance. Autrement dit, le modèle ne voit pas les événements futurs ni les charges futures ; il utilise uniquement l'information qui aurait été disponible pour un opérateur au moment de la prévision. Ce cadre permet de tester si le contexte opérationnel apporte un signal au-delà de la seule saisonnalité.

3.4 Modèles comparés

Deux modèles de référence sont comparés à ce stade. Le premier est un naïf saisonnier : il réutilise le profil historique correspondant au même jour et à la même heure, et produit des quantiles plutôt qu'une simple moyenne. C'est une référence simple mais forte, et le cadre standard de la prévision la recommande comme base de comparaison [6]. Le second ajoute les variables exogènes ci-dessus. Son but n'est pas d'être le modèle final, mais de mesurer si le contexte opérationnel fourni par le jumeau apporte un signal prédictif ; il fait donc le pont entre la couche de configuration et d'événements, d'une part, et la couche de prévision, d'autre part.

Des modèles plus complets sont prévus derrière la même interface : un modèle

statistique de type SARIMAX, un modèle temporel neuronal, puis un modèle de performance sur graphe. Ils devront battre ces références dans les mêmes conditions.

3.5 Architecture en deux étapes

La chaîne de prévision est conçue en deux étapes. La première prédit la demande future sous forme de quantiles. La seconde transforme cet état futur du trafic en indicateurs de service, à savoir délai, gigue, perte et charge de lien.

C'est à la seconde étape qu'un modèle de type RouteNet-Fermi peut être branché [7]. Il faut souligner qu'il ne s'agit pas d'un prédicteur temporel : c'est un modèle de performance qui prend une matrice de trafic future, la topologie et le routage, et en estime les indicateurs de service. La dimension temporelle vient donc entièrement de la première étape. Cette séparation est nette : la première étape dit comment la demande évolue dans le temps, la seconde dit quelle qualité de service en résulte à un instant donné.

3.6 Probabilité de dépassement et incident préventif

Le système ne se limite pas à la médiane. À partir des quantiles prévus, il estime la probabilité que la charge, ou un indicateur de service, dépasse son seuil à chaque horizon. Lorsque cette probabilité franchit un seuil de décision, il émet un incident préventif. Cet incident entre dans la même chaîne que celui produit par la détection, ce qui unifie la voie préventive et la voie agent : le même raisonneur traite un problème constaté et un problème prévu.

4 Protocole d'évaluation

4.1 Rejeu à origine glissante

L'évaluation rejoue la prévision à plusieurs dates de départ successives, en fenêtre d'apprentissage qui s'allonge, sur quatre découpes, ce qui interdit tout usage d'information future. Ce protocole d'évaluation hors échantillon sur une seule série est le cadre standard recommandé pour les séries temporelles [8]. Pour chaque origine t et chaque horizon $h \in \{1, 6, 24, 72, 144\}$ pas de cinq minutes, on compare la valeur réelle y_{t+h} à la prévision $\hat{y}_{t+h}$ et à ses quantiles. L'horizon de travail est $h = 24$. Le jeu compte 1728 points de prévision par horizon.

4.2 Mesures d'erreur

L'erreur ponctuelle est mesurée par l'erreur absolue moyenne mise à l'échelle (MASE), sans unité et comparable entre liens [9] :

$$\text{MASE} = \frac{\frac{1}{H} \sum_h |y_{t+h} - \hat{y}_{t+h}|}{\frac{1}{n-m} \sum_{i=m+1}^n |y_i - y_{i-m}|},$$

où le dénominateur est l'erreur du modèle naïf saisonnier de période m mesurée sur l'apprentissage. Une valeur inférieure à 1 signifie faire mieux que ce naïf de référence. On n'utilise pas le MAPE, instable quand la charge est basse.

La qualité de l'intervalle est mesurée par le score de probabilité classé continu (CRPS), une règle de score strictement propre [10]. Pour une loi prévue de fonction de répartition F et une valeur réalisée y ,

$$\text{CRPS}(F, y) = \int_{-\infty}^{+\infty} (F(z) - \mathbf{1}\{z \geq y\})^2 dz,$$

que l'on approche par la moyenne de la perte quantile sur une grille dense de niveaux τ , avec $\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\})$:

$$\text{CRPS} \approx \frac{2}{|\mathcal{T}|} \sum_{\tau \in \mathcal{T}} \rho_\tau(y - q_\tau).$$

Le CRPS récompense à la fois la justesse et la finesse, et se réduit à l'erreur absolue pour une prévision ponctuelle. La qualité d'un intervalle central de niveau $1 - \alpha$, borné par ℓ et u , est aussi résumée par le score d'intervalle de Winkler :

$$\text{IS}_\alpha = (u - \ell) + \frac{2}{\alpha}(\ell - y) \mathbf{1}\{y < \ell\} + \frac{2}{\alpha}(y - u) \mathbf{1}\{y > u\}.$$

Le gain d'un modèle par rapport au naïf de référence, pour une mesure M , est $\text{Skill} = 1 - M_{\text{modèle}}/M_{\text{réf}}$.

4.3 Test de significativité

Un écart de moyenne ne prouve rien. Pour comparer deux modèles A et B sur une perte ℓ , on forme l'écart de perte $d_t = \ell(e_t^A) - \ell(e_t^B)$ et on teste $\mathbb{E}[d_t] = 0$ par la statistique de Diebold-Mariano [12] :

$$\text{DM} = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}},$$

où la variance est estimée par un noyau tenant compte de l'autocorrélation des erreurs à l'horizon h . On applique la correction en petit échantillon de Harvey, Leybourne et Newbold [13] et un test unilatéral, de sorte qu'une faible p-valeur indique bien une amélioration. Le test est appliqué sur le CRPS pour que la comparaison porte sur l'intervalle et pas seulement sur le point.

4.4 Calibration et dépassement

La calibration se vérifie par la transformée intégrale de probabilité $u_t = F_t(y_t)$, dont la loi doit être uniforme si les intervalles sont justes ; un histogramme en U signale des intervalles trop étroits [11]. La probabilité de dépassement d'une capacité c à l'horizon h se lit sur les quantiles prévus, $\hat{p}_{t,h} = \widehat{\Pr}(y_{t+h} > c)$, et une alerte est émise lorsque $\hat{p}_{t,h}$ franchit un seuil de décision. Comme un dépassement est un événement rare, une pondération de la queue par un CRPS à seuil est une extension prévue pour éviter que les régimes normaux ne diluent la mesure [14].

5 Résultats

Le tableau ci-dessous résume l'horizon de travail.

Modèle	MASE	Skill	CRPS	Skill	MSIS	Couv. 90	Couv. 95	DM (CRPS)
naïf	1,677	réf.	4,427	réf.	28,78	0,92	0,92	(réf.)
naïf + variables	0,482	0,71	1,275	0,71	5,25	1,00	1,00	$p = 0,002$

5.1 Résultat principal

À tous les horizons, le modèle enrichi de variables fait mieux que le naïf. Le gain va de 0,85 à un pas à 0,33 à cent quarante-quatre pas ; il décroît avec l'horizon, ce qui est attendu, mais reste positif partout (figure 3). Ce gain n'est pas un simple écart de moyenne : le test de Diebold-Mariano sur le CRPS à l'horizon de travail conclut à une amélioration significative, $p = 0,002$ (figure 4).




Figure 3: Gain (skill MASE) du modèle enrichi contre le naïf saisonnier, par horizon.

L'erreur croît avec l'horizon pour les deux modèles, le modèle enrichi restant en dessous sur toute la plage (figure 5). En valeur absolue, il fait mieux que le naïf de référence,




Figure 4: Test de Diebold-Mariano sur le CRPS à $h = 24$. La case en bas à gauche indique une différence significative.

c'est-à-dire un MASE inférieur à 1, jusqu'à environ quarante-huit pas ; au-delà, son erreur passe au-dessus de ce repère tout en restant bien inférieure au modèle naïf. L'horizon de travail est donc dans la zone fiable.




Figure 5: Erreur en fonction de l'horizon, en MASE et en CRPS. La ligne pointillée marque le niveau du naïf saisonnier.

Le retrait des variables ajoutées fait remonter l'erreur à l'horizon de travail, de 0,48 à 1,67 en MASE et de 1,28 à 4,43 en CRPS, la différence restant significative (figure 6). C'est la mesure directe de l'apport de la configuration et des événements, et le lien concret entre cette voie et le reste du système.




Figure 6: Effet du retrait des variables ajoutées, en MASE et en CRPS, à $h = 24$.

5.2 Prédiction de dépassement

Sur un cas où un dépassement a lieu, le modèle suit la montée de charge et son intervalle haut franchit le seuil de 85 % au voisinage du dépassement réel, au pas 142 contre le pas 140 (figure 7). Sur cet exemple, l'alerte arrive donc au moment du dépassement, pas nettement avant. Ce point est directement lié à la calibration : des intervalles trop étroits aux horizons longs retardent le franchissement du seuil par le quantile haut.

Sur l'ensemble, le modèle enrichi classe bien mieux les rares dépassements, l'aire sous la courbe précision-rappel passant de 0,01 à 0,57 (figure 8). Cette mesure est plus informative que la courbe ROC pour un événement rare. Il faut toutefois être clair : la fenêtre de test ne contient que trois dépassements. Ce résultat va dans le bon sens mais n'est pas encore solide, et devra être confirmé sur une période qui en contient davantage.

5.3 Calibration

À l'horizon de travail, les intervalles du modèle enrichi sont de la bonne taille : la couverture est proche des niveaux visés et le score d'intervalle est bien meilleur, 5,25 contre 28,78. En moyenne sur tous les horizons, les deux modèles couvrent un peu moins que prévu, leurs intervalles étant un peu trop étroits, le naïf beaucoup plus que l'autre (figure 9).

Le diagnostic par histogramme demande de la prudence. Coupé par modèle et par horizon, chaque case ne contient que douze points, trop peu pour conclure. Le diagnostic fiable est la mesure d'ensemble, sur tous les points : le naïf y est sous-dispersé, le modèle enrichi y est meilleur, ce qui est cohérent avec la couverture (figure 10).

Enfin, le test d'autocorrélation des résidus n'est pas concluant sur ce jeu, faute d'un nombre suffisant de points de résidu ; il sera relancé sur une fenêtre plus longue. Le




Figure 7: Un cas de dépassement : charge réelle, prévision médiane, intervalles, seuil, et moment de l'alerte.




Figure 8: Prédiction de dépassement. À droite, le nombre d'événements est trop faible pour une fiabilité stable ; on se fie à la courbe précision-rappel.




Figure 9: Couverture empirique par rapport au niveau visé, et largeur moyenne des intervalles.




Figure 10: Histogrammes de la transformée intégrale de probabilité. Seules les colonnes d'ensemble, à droite, sont fiables ; les cases par horizon manquent de points.

nuage des résidus ne montre pas de tendance nette, hormis quelques valeurs élevées (figure 11).




Figure 11: Résidus du modèle enrichi.

6 La voie agent : diagnostic agentique

6.1 État actuel

La voie agent est aujourd'hui fonctionnelle, mais elle n'est pas encore pilotée par une interface de modèle de langage. La contrainte est pratique : dans l'environnement de travail actuel, les bibliothèques clientes envisagées pour accéder aux modèles, notamment `llmproxy`, `litellm`, `openai` et `anthropic`, ne s'installent ou ne s'importent pas de manière fiable. Le diagnostic repose donc, dans cette version, sur un raisonneur déterministe à base de règles.

Ce choix n'est pas une solution de secours ni une version réduite de démonstration. C'est un point de référence déterministe, utile en soi. Il rend le banc de test reproductible hors ligne, et il permet de mesurer ce que l'architecture agentique et le jumeau numérique apportent avant même d'introduire un modèle de langage.

6.2 Pourquoi la chaîne reste agentique

Le caractère agentique ne tient pas au type de raisonneur, mais à la structure de la chaîne. Le raisonneur ne produit pas directement une réponse finale ; il suit une boucle d'enquête. À partir d'un incident, il planifie l'enquête, appelle des outils de diagnostic, observe leurs résultats, classe les hypothèses, valide par rejeu contrefactuel dans une copie du jumeau, puis conclut avec une cause, une chaîne de preuves, les clients impactés et un niveau de confiance.

6.3 Déroulé du diagnostic

L'entrée est un incident, qui porte un horodatage, des symptômes et un périmètre initial. Le raisonneur localise d'abord, dans la télémétrie, le moment d'apparition des symptômes. Il inspecte ensuite les différences entre configuration courante et configuration de référence sur les équipements. Il interroge l'état des sessions BGP et des adjacences IS-IS. En cas de congestion, il analyse le lien affecté, le trafic sur ce lien, les clients touchés, et compare le chemin courant au chemin de référence. Il forme alors des causes candidates, en s'appuyant sur l'alignement temporel et sur le caractère injectable de la cause. Il distingue explicitement la cause de l'effet : une congestion est en général un effet, elle n'est pas retenue directement comme cause racine. Enfin, il soumet les meilleures hypothèses à une validation contrefactuelle : il rejoue la panne supposée dans la copie du jumeau et vérifie si les symptômes se reproduisent. C'est cette étape qui distingue le système d'un simple appel à un modèle : une cause n'est retenue que si son rejeu reproduit les symptômes observés.

6.4 Outils de diagnostic

Le raisonneur dispose d'un jeu d'outils qu'il appelle au cours de la boucle : `shortest_path` pour le chemin le plus court, `get_link_traffic` pour le trafic d'un lien, `get_affected_clients` pour les clients touchés, `get_topology_neighbours` pour les voisins de topologie, `get_bgp_state` et `get_isis_adjacencies` pour l'état du plan de contrôle, `get_device_config` et `diff_config` pour la configuration et sa dérive, `read_telemetry` pour les séries de télémétrie, et `counterfactual_inject` pour le rejeu d'une hypothèse dans le jumeau.

6.5 Relation au futur raisonneur fondé sur un modèle de langage

Le raisonneur à base de règles et le futur raisonneur fondé sur un modèle de langage partagent la même interface. Ils appellent le même jeu d'outils et produisent le même rapport structuré de cause racine. Le raisonneur à base de règles constitue donc un témoin expérimental. Lorsqu'un modèle de langage sera branché derrière la même interface, il ne s'agira pas seulement de vérifier s'il sait répondre, mais de le comparer dans des conditions contrôlées : exactitude du diagnostic, nombre d'appels d'outils, temps avant conclusion, cohérence de la chaîne de preuves, taux de validation contrefactuelle, et robustesse entre scénarios. Ce protocole vise à éviter le piège d'un modèle qui paraît intelligent mais dont la réponse n'est pas vérifiable. Cette approche rejoint les travaux récents sur le diagnostic réseau assisté par plusieurs agents [15] et sur les bancs d'évaluation dédiés au dépannage réseau [16] ; la vérification statique de configuration offre par ailleurs une base éprouvée pour une partie des tests contrefactuels [17]. La contribution principale n'est donc pas l'usage d'un modèle de langage, mais la construction d'une boucle de diagnostic vérifiable.

7 Validité des résultats

Ce qui est solide repose sur l'ensemble des points : le classement des deux modèles sur le MASE et le CRPS, le gain à tous les horizons, la significativité par Diebold-Mariano, et l'effet des variables ajoutées tiennent sur 1728 points par horizon.

Ce qui n'est pas encore solide repose sur peu de points : la prévision de dépassement s'appuie sur trois événements, le diagnostic de calibration par horizon manque de points et seul l'ensemble est fiable, et le test de résidus est à relancer. Ces limites ne remettent pas en cause le résultat principal ; elles demandent plus de données.

Deux limites de périmètre subsistent. Les données proviennent encore du jumeau simulé, et non de données historiques réelles de la plateforme NUAR. Et la généralisation visée à ce stade est intra-topologie, entre scénarios et routes différentes, pas une généralisation à tout réseau.

8 Conclusion et prochaines étapes

Le protocole d'évaluation est en place et rigoureux, et il sera réutilisé pour tout modèle futur. Même avec des modèles de référence simples, l'ajout des variables issues de la configuration et des événements apporte un gain net, significatif et vérifiable à l'horizon de travail. La voie agent est fonctionnelle sur un raisonneur déterministe qui sert de référence contrôlée pour l'introduction future d'un modèle de langage.

Les étapes suivantes sont d'ajouter au banc des modèles plus complets, dont le modèle sur graphe qui transforme la prévision de charge en prévision de délai et de perte [7] ; de traiter la couverture des intervalles par une méthode à garantie, la prédiction conforme [18], ce qui devrait aussi avancer le moment de l'alerte ; d'alimenter le banc en données historiques réelles de la plateforme NUAR, pour sortir des seules données du jumeau et disposer de plus de dépassements ; et, avec l'équipe Innovation, d'estimer la matrice de trafic, entrée manquante du modèle sur graphe.

Références

- [1] D. Oppenheimer, A. Ganapathi, and D. A. Patterson, "Why do Internet services fail, and what can be done about it?" in *Proc. 4th USENIX Symp. Internet Technologies and Systems*, 2003.
- [2] Uptime Institute, *Annual Outage Analysis 2024*, 2024.
- [3] S. Kobayashi, K. Otomo, K. Fukuda, and H. Esaki, "Causal analysis of network logs with layered protocols and topology knowledge," in *Proc. IFIP/IEEE CNSM*, 2019.
- [4] C. Zhou et al., "Network Digital Twin: Concepts and reference architecture," IRTF Internet-Draft draft-irtf-nmrg-network-digital-twin-arch, 2026.
- [5] ETSI, *TS 128 561: 5G; Management and orchestration; Management aspects of Network Digital Twins*, 2025.

- [6] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021.
- [7] M. Ferriol-Galmés et al., "RouteNet-Fermi: Network modeling with graph neural networks," *IEEE/ACM Trans. Netw.*, vol. 31, no. 6, pp. 2633–2647, 2023.
- [8] L. J. Tashman, "Out-of-sample tests of forecasting accuracy: an analysis and review," *Int. J. Forecasting*, vol. 16, no. 4, pp. 437–450, 2000.
- [9] R. J. Hyndman and A. B. Koehler, "Another look at measures of forecast accuracy," *Int. J. Forecasting*, vol. 22, no. 4, pp. 679–688, 2006.
- [10] T. Gneiting and A. E. Raftery, "Strictly proper scoring rules, prediction, and estimation," *J. Amer. Statist. Assoc.*, vol. 102, no. 477, pp. 359–378, 2007.
- [11] T. Gneiting, F. Balabdaoui, and A. E. Raftery, "Probabilistic forecasts, calibration and sharpness," *J. Roy. Statist. Soc. B*, vol. 69, no. 2, pp. 243–268, 2007.
- [12] F. X. Diebold and R. S. Mariano, "Comparing predictive accuracy," *J. Bus. Econ. Statist.*, vol. 13, no. 3, pp. 253–263, 1995.
- [13] D. Harvey, S. Leybourne, and P. Newbold, "Testing the equality of prediction mean squared errors," *Int. J. Forecasting*, vol. 13, no. 2, pp. 281–291, 1997.
- [14] T. Gneiting and R. Ranjan, "Comparing density forecasts using threshold- and quantile-weighted scoring rules," *J. Bus. Econ. Statist.*, vol. 29, no. 3, pp. 411–422, 2011.
- [15] Z. Wang et al., "Intent-driven network management with multi-agent LLMs: The Confucius framework," in *Proc. ACM SIGCOMM*, 2025.
- [16] Authors of NIKA, "A network arena for benchmarking AI agents on network troubleshooting," arXiv preprint, 2025.
- [17] A. Fogel et al., "A general approach to network configuration analysis," in *Proc. USENIX NSDI*, 2015.
- [18] A. N. Angelopoulos and S. Bates, "A gentle introduction to conformal prediction and distribution-free uncertainty quantification," arXiv:2107.07511, 2021.