

Détection, diagnostic et prévision sur jumeau numérique réseau

Rapport d'étape sur la mise en place et l'évaluation de la voie de prévision

Lizhan Hong · École Polytechnique · Orange Wholesale (OW / OINIS)

Juillet 2026

Table des matières

Résumé	1
1 Introduction et objectif	2
2 Vue d'ensemble du système	2
3 Protocole d'évaluation	4
3.1 Rejeu à origine glissante	4
3.2 Mesures d'erreur	4
3.3 Test de significativité	5
3.4 Calibration et dépassement	5
4 Résultats	5
4.1 Résultat principal : net et vérifié	5
4.2 Prévision de dépassement : fonctionnelle, mais peu d'exemples	7
4.3 Calibration : correcte à l'horizon de travail, à surveiller plus loin	8
4.4 Résidus : test à refaire	10
5 Validité des résultats	10
6 Corrections apportées ce cycle	11
7 Conclusion et prochaines étapes	11
Références	11

Résumé

Le projet construit, au-dessus d'un jumeau numérique du réseau, un système qui détecte les incidents, en cherche la cause, et prévoit les dépassements de charge avant qu'ils ne surviennent. Le système suit deux voies complémentaires : une voie quantitative qui prévoit la charge et produit une alerte, et une voie de diagnostic où un agent cherche la

cause d'un incident et la vérifie en la rejouant dans le jumeau. Ce rapport porte sur la voie quantitative et sur son protocole d'évaluation. Sur deux modèles de référence, un modèle naïf saisonnier et le même enrichi de variables connues d'avance, l'ajout de ces variables réduit l'erreur à tous les horizons, avec un gain de 0,71 à l'horizon de travail, statistiquement significatif au test de Diebold-Mariano ($p = 0,002$). Ce résultat repose sur 1728 points de prévision par horizon et est jugé solide. Deux résultats secondaires, la prévision de dépassement et le diagnostic de calibration par horizon, reposent sur trop peu de points et sont donnés comme indicatifs. Le protocole d'évaluation, réutilisable pour tout modèle futur, est le principal produit de ce cycle.

1 Introduction et objectif

Trois constats motivent le projet. Les erreurs et changements de configuration sont la première cause humaine de panne réseau. Dans le temps de rétablissement d'un incident, les phases les plus longues sont la détection et le diagnostic. Enfin, poser un diagnostic demande de rapprocher des preuves de natures différentes, la configuration, la télémétrie et la topologie, ce qu'un opérateur fait lentement.

Le système répond à ces trois points. Il détecte automatiquement un incident, il en analyse la cause, et il anticipe les dégradations de charge. Sa particularité est de disposer d'un jumeau numérique, ce qui permet de vérifier chaque hypothèse de cause en la rejouant, au lieu de s'en remettre à une réponse plausible mais invérifiable.

Ce rapport documente l'état de la voie de prévision et, surtout, la mise en place d'un protocole d'évaluation rigoureux. Les modèles évalués ici sont volontairement simples : l'objectif de ce cycle est d'établir la méthode de mesure et une base de comparaison, pas de proposer le modèle final.

2 Vue d'ensemble du système

Le système suit deux voies qui ne fonctionnent pas de la même façon.

La voie quantitative calcule des chiffres. À partir de l'historique de charge et de variables connues d'avance, à savoir les changements de configuration, les événements et le calendrier, elle prévoit la charge future avec un intervalle, puis en déduit une probabilité de dépassement. Quand cette probabilité franchit un seuil, elle produit une intention : un dépassement est prévu dans un certain nombre de pas.

La voie de diagnostic raisonne sur un incident. La détection repère une anomalie ou une dérive et ouvre un incident ; un agent le reprend, appelle des outils pour rassembler des preuves, propose une cause, la vérifie dans le jumeau, puis conclut.

Les deux voies se rejoignent : un dépassement prévu est traité comme un incident préventif par le même agent, avant la panne. C'est le même objet et le même agent des deux côtés, seule l'origine change, un fait constaté ou un fait prévu (figure 1). L'agent ne détermine pas la cause en une fois ; il procède par étapes et se sert du jumeau pour valider chaque hypothèse (figure 2).

Figure 1 — Les deux voies et leur point de rencontre

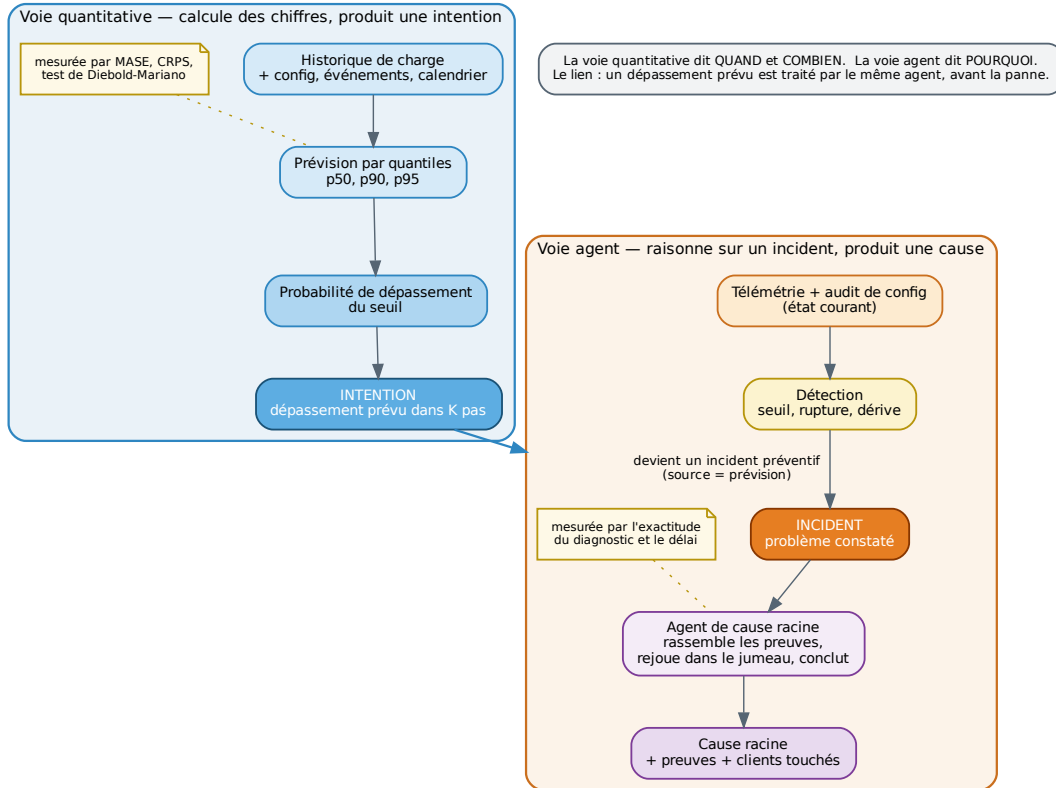


Figure 1: Les deux voies et leur point de rencontre.




Figure 2: La boucle de diagnostic.

3 Protocole d'évaluation

3.1 Rejeu à origine glissante

L'évaluation rejoue la prévision à plusieurs dates de départ successives, en fenêtre d'apprentissage qui s'allonge, sur quatre découpes, ce qui interdit tout usage d'information future. Pour chaque origine t et chaque horizon $h \in \{1, 6, 24, 72, 144\}$ pas de cinq minutes, on compare la valeur réelle y_{t+h} à la prévision $\hat{y}_{t+h}$ et à ses quantiles. L'horizon de travail est $h = 24$. Le jeu compte 1728 points de prévision par horizon.

3.2 Mesures d'erreur

L'erreur ponctuelle est mesurée par l'erreur absolue moyenne mise à l'échelle (MASE), sans unité et comparable entre liens :

$$\text{MASE} = \frac{\frac{1}{H} \sum_h |y_{t+h} - \hat{y}_{t+h}|}{\frac{1}{n-m} \sum_{i=m+1}^n |y_i - y_{i-m}|},$$

où le dénominateur est l'erreur du modèle naïf saisonnier de période m mesurée sur l'apprentissage. Une valeur inférieure à 1 signifie faire mieux que ce naïf de référence. On n'utilise pas le MAPE, instable quand la charge est basse.

La qualité de l'intervalle est mesurée par le score de probabilité classé continu (CRPS). Pour une loi prévue de fonction de répartition F et une valeur réalisée y ,

$$\text{CRPS}(F, y) = \int_{-\infty}^{+\infty} (F(z) - \mathbf{1}\{z \geq y\})^2 dz,$$

que l'on approche par la moyenne de la perte quantile sur une grille dense de niveaux τ , avec $\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\})$:

$$\text{CRPS} \approx \frac{2}{|\mathcal{T}|} \sum_{\tau \in \mathcal{T}} \rho_\tau(y - q_\tau).$$

Le CRPS est une règle de score strictement propre : il récompense à la fois la justesse et la finesse, et se réduit à l'erreur absolue pour une prévision ponctuelle. La qualité d'un intervalle central de niveau $1 - \alpha$, borné par ℓ et u , est aussi résumée par le score d'intervalle de Winkler :

$$\text{IS}_\alpha = (u - \ell) + \frac{2}{\alpha}(\ell - y) \mathbf{1}\{y < \ell\} + \frac{2}{\alpha}(y - u) \mathbf{1}\{y > u\}.$$

Le gain d'un modèle par rapport au naïf de référence, pour une mesure M , est $\text{Skill} = 1 - M_{\text{modèle}}/M_{\text{réf}}$.

3.3 Test de significativité

Un écart de moyenne ne prouve rien. Pour comparer deux modèles A et B sur une mesure de perte ℓ , on forme l'écart de perte $d_t = \ell(e_t^A) - \ell(e_t^B)$ et on teste $\mathbb{E}[d_t] = 0$ par la statistique de Diebold-Mariano

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}},$$

où la variance est estimée par un noyau tenant compte de l'autocorrélation des erreurs à l'horizon h . On applique la correction en petit échantillon de Harvey, Leybourne et Newbold, et un test unilatéral, de sorte qu'une faible p-valeur indique bien une amélioration. Le test est appliqué sur le CRPS pour que la comparaison porte sur l'intervalle et pas seulement sur le point.

3.4 Calibration et dépassement

La calibration se vérifie par la transformée intégrale de probabilité $u_t = F_t(y_t)$, dont la loi doit être uniforme si les intervalles sont justes ; un histogramme en U signale des intervalles trop étroits. Enfin, la probabilité de dépassement d'une capacité c à l'horizon h se lit sur les quantiles prévus, $\hat{p}_{t,h} = \Pr(y_{t+h} > c)$, et une alerte est émise lorsque $\hat{p}_{t,h}$ franchit un seuil de décision.

4 Résultats

Le tableau ci-dessous résume l'horizon de travail.

Modèle	MASE	Skill	CRPS	Skill	MSIS	Couv. 90	Couv. 95	DM (CRPS)
naïf	1,677	réf.	4,427	réf.	28,78	0,92	0,92	(réf.)
naïf + variables	0,482	0,71	1,275	0,71	5,25	1,00	1,00	$p =$ 0,002

4.1 Résultat principal : net et vérifié

À tous les horizons, le modèle enrichi de variables fait mieux que le naïf. Le gain va de 0,85 à un pas à 0,33 à cent quarante-quatre pas ; il décroît avec l'horizon, ce qui est attendu, mais reste positif partout (figure 3). Ce gain n'est pas un simple écart de moyenne : le test de Diebold-Mariano sur le CRPS à l'horizon de travail conclut à une amélioration significative, $p = 0,002$ (figure 4).

L'erreur croît avec l'horizon pour les deux modèles, le modèle enrichi restant en dessous sur toute la plage (figure 5). En valeur absolue, il fait mieux que le naïf de référence, c'est-à-dire un MASE inférieur à 1, jusqu'à environ quarante-huit pas ; au-delà, son




Figure 3: Gain (skill MASE) du modèle enrichi contre le naïf saisonnier, par horizon.




Figure 4: Test de Diebold-Mariano sur le CRPS à $h = 24$. La case en bas à gauche indique une différence significative.

erreur passe au-dessus de ce repère tout en restant bien inférieure au modèle naïf. L'horizon de travail est donc dans la zone fiable.




Figure 5: Erreur en fonction de l'horizon, en MASE et en CRPS. La ligne pointillée marque le niveau du naïf saisonnier.

Le retrait des variables ajoutées fait remonter l'erreur à l'horizon de travail, de 0,48 à 1,67 en MASE et de 1,28 à 4,43 en CRPS, la différence restant significative (figure 6). C'est la mesure directe de l'apport de la configuration et des événements, et le lien concret entre cette voie et le reste du système.




Figure 6: Effet du retrait des variables ajoutées, en MASE et en CRPS, à $h = 24$.

4.2 Prédiction de dépassement : fonctionnelle, mais peu d'exemples

Sur un cas où un dépassement a lieu, le modèle suit la montée de charge et son intervalle haut franchit le seuil de 85 % au voisinage du dépassement réel, au pas 142 contre le

pas 140 (figure 7). Sur cet exemple, l’alerte arrive donc au moment du dépassement, pas nettement avant. Ce point est directement lié à la calibration : des intervalles trop étroits aux horizons longs retardent le franchissement du seuil par le quantile haut.




Figure 7: Un cas de dépassement : charge réelle, prévision médiane, intervalles, seuil, et moment de l’alerte.

Sur l’ensemble, le modèle enrichi classe bien mieux les rares dépassements, l’aire sous la courbe précision-rappel passant de 0,01 à 0,57 (figure 8). Il faut toutefois être clair : la fenêtre de test ne contient que trois dépassements. Ce résultat va dans le bon sens mais n’est pas encore solide, et devra être confirmé sur une période qui en contient davantage.

4.3 Calibration : correcte à l’horizon de travail, à surveiller plus loin

À l’horizon de travail, les intervalles du modèle enrichi sont de la bonne taille : la couverture est proche des niveaux visés et le score d’intervalle est bien meilleur, 5,25 contre 28,78. En moyenne sur tous les horizons, les deux modèles couvrent un peu moins que prévu, leurs intervalles étant un peu trop étroits, le naïf beaucoup plus que l’autre (figure 9).

Le diagnostic par histogramme demande de la prudence. Coupé par modèle et par horizon, chaque case ne contient que douze points, trop peu pour conclure, d’où la mention « indéterminé ». Le diagnostic fiable est la colonne d’ensemble, sur tous les points : le naïf y est sous-dispersé, le modèle enrichi y est meilleur, ce qui est cohérent avec la couverture (figure 10).




Figure 8: Prédiction de dépassement. À droite, le nombre d'événements est trop faible pour une fiabilité stable ; on se fie à la courbe précision-rappel.




Figure 9: Couverture empirique par rapport au niveau visé, et largeur moyenne des intervalles.

Histogrammes PIT — densité normalisée (Idéal=1, bande grise = bande de cohérence 90% U(0,1)); colonne AGRÉGAT = diagnostic fiable




Figure 10: Histogrammes de la transformée intégrale de probabilité. Seules les colonnes d'ensemble, à droite, sont fiables ; les cases par horizon manquent de points.

4.4 Résidus : test à refaire

Le test d'autocorrélation des résidus n'a pas abouti sur ce tirage, sa p-valeur étant sortie indéterminée faute d'assez de points ; il est sans conclusion et sera relancé avec plus de données. Le nuage des résidus ne montre pas de tendance nette, hormis quelques valeurs élevées (figure 11).




Figure 11: Résidus du modèle enrichi. Le test d'autocorrélation est à refaire.

5 Validité des résultats

Ce qui est solide repose sur l'ensemble des points : le classement des deux modèles sur le MASE et le CRPS, le gain à tous les horizons, la significativité par Diebold-Mariano, et l'effet des variables ajoutées tiennent sur 1728 points par horizon.

Ce qui n'est pas encore solide repose sur peu de points : la prévision de dépassement

s'appuie sur trois événements, le diagnostic de calibration par horizon manque de points et seul l'ensemble est fiable, et le test de résidus est à refaire. Ces trois limites ne remettent pas en cause le résultat principal ; elles demandent plus de données.

6 Corrections apportées ce cycle

Trois figures étaient trompeuses au tirage précédent et ont été corrigées à la source. Le graphique en éventail était vide car il visait une origine sans séquence de prévision ; il choisit désormais une origine où un dépassement a lieu et trace la séquence complète. Les histogrammes de calibration affichaient des étiquettes qui changeaient d'un horizon à l'autre sans raison ; le nombre de points par case étant trop faible, ces cases sont maintenant marquées « indéterminé » et seul l'ensemble est jugé. Le diagramme de fiabilité était instable faute d'événements ; il indique désormais leur nombre et renvoie à la courbe précision-rappel.

7 Conclusion et prochaines étapes

Le protocole d'évaluation est en place et rigoureux, et il sera réutilisé pour tout modèle futur. Même avec des modèles de référence simples, l'ajout des variables issues de la configuration et des événements apporte un gain net, significatif et vérifiable à l'horizon de travail.

Les étapes suivantes sont d'ajouter au banc des modèles plus complets, dont le modèle sur graphe qui transforme la prévision de charge en prévision de délai et de perte ; de traiter la couverture des intervalles par une méthode à garantie, la prédiction conforme, ce qui devrait aussi avancer le moment de l'alerte ; d'alimenter le banc en données historiques réelles de la plateforme NUAR, pour sortir des seules données du jumeau et disposer de plus de dépassements ; et, avec l'équipe Innovation, d'estimer la matrice de trafic, entrée manquante du modèle sur graphe.

Références

1. R. J. Hyndman, A. B. Koehler. *Another look at measures of forecast accuracy*. International Journal of Forecasting, 2006.
2. T. Gneiting, A. E. Raftery. *Strictly proper scoring rules, prediction, and estimation*. Journal of the American Statistical Association, 2007.
3. T. Gneiting, F. Balabdaoui, A. E. Raftery. *Probabilistic forecasts, calibration and sharpness*. Journal of the Royal Statistical Society B, 2007.
4. F. X. Diebold, R. S. Mariano. *Comparing predictive accuracy*. Journal of Business and Economic Statistics, 1995.
5. D. Harvey, S. Leybourne, P. Newbold. *Testing the equality of prediction mean squared errors*. International Journal of Forecasting, 1997.
6. A. N. Angelopoulos, S. Bates. *A gentle introduction to conformal prediction and distribution-free uncertainty quantification*. 2021.

7. M. Ferriol-Galmés et al. *RouteNet-Fermi: network modeling with graph neural networks*. IEEE/ACM Transactions on Networking, 2023.